

Reporte Etapa 2 — Clasificación EEG single-trial match vs mismatch

Autores: Jose Pablo Agüero Mora, Roilin Navarro Vargas

Curso: Inteligencia Artificial

Etapa 2: Modelado, evaluación y análisis

1. Problema y decisiones que se arrastran de la etapa 1

El objetivo en esta etapa es clasificar ensayos individuales (single-trial) de EEG de una tarea de juicio de relación semántica (Semantic Relatedness Judgment Task). En cada ensayo se presenta un par de palabras y el target puede corresponder a una condición relacionada (match) o no relacionada (mismatch). Con base en eso, el problema de ML se define como clasificación binaria: predecir match vs mismatch a partir de EEG.


En la etapa 1 se revisó la estructura del dataset y se decidió usar un pipeline realista para EEG de consumo (señal ruidosa y con variación por sujeto). Para esta etapa se mantienen varias decisiones técnicas que afectan todo el modelado. Primero, se trabaja con el subconjunto "Included" de EEG procesado, que ya viene epocheado (es decir, los archivos ya traen ensayos segmentados, no señal continua). Segundo, para reducir ruido conductual se filtra a ensayos correctos usando eventos del tipo matchTarget/Correct y mismatchTarget/Correct. Tercero, el modelado se hace con dos canales (AF7 y AF8) porque son los canales presentes en los archivos procesados usados por el pipeline. Esto explica por qué en el BIDS crudo se observan 4 canales (TP9, AF7, AF8, TP10) pero en el conjunto procesado para ML se trabaja con 2 (AF7/AF8).

También se trabaja con 256 Hz en los archivos procesados del pipeline. Aunque en el artículo del dataset se menciona 250 Hz como muestreo del stream original, el flujo de trabajo que usamos para el modelado queda consistente a 256 Hz a nivel de los archivos procesados y la configuración de los notebooks. Finalmente, se fija una ventana de epochs de -100 ms a 900 ms con baseline de -100 a 0 ms, y se define una ventana N400 de 250 a 600 ms como referencia, ya que el componente N400 típicamente se analiza alrededor de esa latencia.

Como resultado, el enfoque de modelado es tabular (ML clásico) con extracción de características por ensayo, en lugar de entrenar una red directamente con señal cruda.


Figura de chequeo inicial del ERP (sanity check):

ERP promedio — mu02erp (AF8 = electrodo del cluster N400)



Promedio general del ERP:

Grand-average ERP: N = 29 sujetos



2. Dataset y protocolo experimental

2.1 Qué datos entran al modelo

Después del preprocesamiento y construcción del dataset final, los datos usados para ML quedan con estas dimensiones:


- 29 sujetos (conjunto Included)
- 2 canales: AF7 y AF8
- 72 features por ensayo
- 1503 ensayos válidos para entrenamiento/evaluación
- distribución de clases: 865 match (57.6%) y 638 mismatch (42.4%)


Durante el preprocesamiento aparece además un CSV maestro de 1520 filas donde 17 ensayos quedan marcados como malformados/no utilizables (label -1). Para el modelado se usan únicamente los 1503 ensayos válidos.

Para dar contexto a las features: las 72 características se construyen como un conjunto mixto de medidas temporales (por ejemplo varianza, peak-to-peak, pendiente), medidas frecuenciales (potencia por bandas y ratios como theta/alpha o beta/alpha) y medidas inter-canal (diferencias AF7–AF8). Estas medidas se calculan tanto sobre la ventana N400 como sobre la epoch completa, porque el objetivo no es asumir que todo el efecto está concentrado en una sola ventana.

Chequeo de consistencia de una feature clave y correlaciones:

Sanity check: temp_mean_AF8_N400
(amplitud media en AF8 en ventana 250-600 ms)





2.2 Cómo se parte el dataset y cómo evitamos fuga de información

En EEG, muchas epochs del mismo sujeto se parecen entre sí. Si se mezclan al azar entre entrenamiento y prueba, el modelo puede aprender patrones del sujeto y parecer mejor de lo que realmente generaliza. Por eso, la partición se hace por sujeto, no por ensayo.

Se utiliza un esquema fijo:

- conjunto de validación cruzada (CV): 24 sujetos, 1238 epochs
- conjunto holdout (test final): 5 sujetos, 265 epochs

Sujetos holdout: mu05erp, mu17erp, mu24erp, mu27erp, mu36erp.

En CV, la evaluación se hace con GroupKFold (k=5) agrupando por subject_id. Además, cualquier transformación (por ejemplo StandardScaler) se aplica dentro de un pipeline y se ajusta únicamente con datos del fold de entrenamiento. Con esto se evita fuga por normalización. Este mismo protocolo se mantiene en baselines, comparación de modelos, tuning y curvas de aprendizaje, para que las comparaciones sean justas.

3. Baselines (piso de desempeño)



Se definieron cuatro baselines para no comparar el modelo "contra nada", y para tener una idea del piso real del problema. Todos se evalúan con GroupKFold (k=5) en CV y se reporta intervalo de confianza 95% por bootstrap.

Tabla de baselines (CV):

Modelo	Accuracy	Macro F1	ROC-AUC
Dummy (stratified)	0.509 [0.482, 0.538]	0.498 [0.472, 0.527]	0.498 [0.472, 0.527]
Dummy (most_frequent)	0.572 [0.544, 0.600]	0.364 [0.352, 0.375]	0.500
Heurístico ERP (LogReg, 2 features)	0.502 [0.474, 0.531]	0.501 [0.473, 0.529]	0.506 [0.472, 0.540]
Heurístico ERP extendido (4 features)	0.519 [0.491, 0.546]	0.516 [0.487, 0.542]	0.512 [0.481, 0.546]

Lo que se ve aquí es que el dummy estratificado da macro F1 cerca de 0.5, que funciona como piso razonable. El baseline basado solo en amplitud media en N400 no mejora de forma clara, lo que es coherente con la dificultad del single-trial EEG: el N400 suele verse más claro al promediar muchos ensayos, pero a nivel de ensayo individual el ruido y la variación por sujeto lo complican.

Figuras de baselines:



4. Modelos candidatos y modelo elegido

4.1 Comparación inicial sin tuning


Se probaron cinco familias de modelos con el conjunto de CV (24 sujetos) usando GroupKFold k=5. En esta fase la idea era comparar familias, no exprimir el máximo rendimiento.

Tabla de modelos sin tuning (CV):


Modelo	Macro F1	Accuracy	ROC-AUC	Tiempo (s)
LogisticRegression_L2	0.520 [0.494, 0.549]	0.529 [0.502, 0.558]	0.515 [0.484, 0.549]	0.94
LightGBM	0.518 [0.491, 0.545]	0.543 [0.515, 0.571]	0.527 [0.496, 0.559]	14.10
SVM_RBF	0.510 [0.484, 0.538]	0.529 [0.503, 0.558]	0.528 [0.497, 0.560]	4.98
XGBoost	0.495 [0.469, 0.522]	0.517 [0.490, 0.545]	0.509 [0.478, 0.541]	28.64
RandomForest	0.446 [0.421, 0.473]	0.547 [0.519, 0.573]	0.516 [0.485, 0.550]	27.27

En esta comparación el mejor baseline (heurístico extendido, macro F1=0.516) queda bastante cerca de varios modelos sin tuning. LogisticRegression_L2 es apenas superior, lo que motivó hacer ajuste de hiperparámetros: cuando las diferencias son pequeñas, una búsqueda razonable puede decidir mejor entre familias.


Figuras de modelos sin tuning:



Curvas ROC — modelos candidatos



Matrices de confusión (predicciones cross-validated)



4.2 Tuning y selección final


Se aplicó Optuna (100 trials por modelo) a dos candidatos cercanos: LogisticRegression y LightGBM. El objetivo de optimización fue macro F1 en CV con GroupKFold por sujeto.

Resultados del tuning (CV):

Modelo	Macro F1
LightGBM (tuned)	0.558 [0.531, 0.587]
LogisticRegression (tuned)	0.535 [0.508, 0.562]

Se seleccionó LightGBM tuneado porque alcanza el mejor macro F1 en CV y muestra una mejora más clara sobre el baseline extendido.

Resumen visual del tuning:



El modelo final y sus hiperparámetros quedan guardados en `models/best_model.pkl` y `models/best_hyperparameters.json`.

5. Resultados finales, errores y generalización por sujeto


5.1 Evaluación final en holdout

El holdout contiene 265 epochs de 5 sujetos no vistos en entrenamiento ni tuning. Resultados del modelo final (LightGBM tuned):

- Accuracy: 0.595 [0.528, 0.649]
- Macro F1: 0.584 [0.521, 0.643]
- ROC-AUC: 0.586 [0.515, 0.657]

En comparación con CV, el macro F1 en holdout queda ligeramente mayor ($\Delta \approx +0.026$), pero con un intervalo más ancho, lo cual es esperable por el tamaño pequeño del holdout.

Figura de evaluación holdout:




5.2 Qué tan distinto es el desempeño entre sujetos

En EEG el comportamiento del modelo puede cambiar bastante entre sujetos. En holdout, el mejor y peor sujeto fueron:

- mu36erp: macro F1 = 0.683
- mu05erp: macro F1 = 0.425

Eso da un rango inter-sujeto de 0.257 en macro F1. Esta variación es importante porque muestra que el promedio no cuenta toda la historia: algunos sujetos tienen señal más ruidosa o patrones menos consistentes.


Figura de LOSO (variación por sujeto):



5.3 Curvas de aprendizaje y qué nos dicen sobre el comportamiento del modelo

Las curvas de aprendizaje se calculan sobre CV con GroupKFold por sujeto. El gap train-validación al final es 0.171. Esto apunta a que el modelo aprende patrones del training, pero la validación se queda atrás, lo cual es coherente con un dominio ruidoso y con variación por sujeto. En single-trial EEG no es raro que el desempeño esté limitado más por la señal que por el modelo.


Figura de curvas de aprendizaje:



5.4 Confianza y calibración

Se revisa la confianza usando $\max(p, 1-p)$ y una calibración simple por bins. La idea aquí no es decir que el modelo está “perfectamente calibrado”, sino ver si los errores tienden a ocurrir cerca de 0.5 (casos ambiguos) o si hay errores con probabilidades altas, lo cual sería más preocupante.

Figura de confianza y calibración:



5.5 LOSO como vista complementaria

Para ver generalización por sujeto de forma más directa, se ejecutó Leave-One-Subject-Out sobre los 29 sujetos:

- macro F1: 0.514 ± 0.091
- accuracy: 0.556 ± 0.096
- AUC: 0.545 ± 0.096

El promedio es moderado y la desviación muestra que hay sujetos "más fáciles" y "más difíciles", algo que coincide con el análisis de holdout.

6. Explicabilidad con SHAP (qué está usando el modelo)


Para ver qué features están influyendo más en el modelo final, se aplicó SHAP (TreeExplainer) sobre el holdout.

Las 5 features con mayor $|\text{SHAP}|$ promedio fueron:

1. freq_ratio_theta_alpha_AF8_full, $|\text{SHAP}| = 0.0689$
2. temp_var_AF7_full, $|\text{SHAP}| = 0.0660$
3. temp_ptp_AF7_full, $|\text{SHAP}| = 0.0590$
4. temp_slope_AF7_N400, $|\text{SHAP}| = 0.0327$
5. cross_diff_beta_N400, $|\text{SHAP}| = 0.0310$


En conjunto, esto sugiere que el modelo se apoya bastante en medidas de variabilidad temporal (varianza, peak-to-peak, pendientes) y en ratios/potencias espectrales, más que en usar únicamente la amplitud media del N400.

Vista global (SHAP):




Dependence plots:

SHAP dependence plots — Top 5 features



Agrupación por categorías:





Sobre esa agrupación, la suma de importancia SHAP (mean_abs_shap) queda dominada por:

- familia temporal > frecuencial > inter-canal
- AF7 > AF8 (y luego cross)
- ventana full > ventana N400


Esto cuadra con lo que se observa también en ablations: la epoch completa aporta más información que la ventana N400 sola.

Casos locales (cómo se lee un ejemplo): En la figura de casos locales se muestran ejemplos representativos (correctos y errores). Lo valioso aquí es ver que una predicción no depende de una sola variable: el modelo combina varias features y, cuando la probabilidad queda cerca de 0.5, es normal que aparezcan errores porque el caso es ambiguo.





Validación teórica (comparación con univariado):



7. Ablaciones (qué pasa si quitamos partes del pipeline)


En esta sección se repite el entrenamiento en CV con el mismo protocolo, pero quitando partes específicas del conjunto de features o cambiando la ventana/canal. La línea base es el pipeline completo:

- línea base: macro F1 = 0.558 [0.531, 0.587]

Los resultados más relevantes se pueden leer así:

- si se usa solo la ventana N400 (250–600 ms), el macro F1 baja a 0.491 ($\Delta = -0.067$)
- si se usa solo la epoch completa, el macro F1 queda prácticamente igual a la línea base ($\Delta \approx 0$)
- si se usa solo AF7, el modelo baja poco ($\Delta = -0.011$)
- si se usa solo AF8, el descenso es mayor ($\Delta = -0.047$)
- usar solo una familia de features baja el desempeño, especialmente inter-canal ($\Delta = -0.066$)

Figura comparativa de ablations:



En general, aquí se ve que el modelo “completo” gana porque mezcla familias de features, y que la información más útil no se concentra únicamente en N400, sino en la epoch completa y en medidas de variabilidad (temporal y frecuencial).

8. Reproducibilidad y repositorio

El proyecto se organiza como un repositorio con carpetas separadas para configuración, notebooks y resultados. La ejecución está pensada como pipeline por notebooks (00 al 08) y cada notebook guarda outputs en [reports/](#), [figures/](#), [models/](#) y [features/](#).

Las dependencias del proyecto están listadas en el archivo [requirements.txt](#).

En general, la estructura relevante para reproducibilidad es:

- configs/main_config.yaml (parámetros principales, ventanas, seed, canales)
- notebooks numerados (00 al 08) que se ejecutan en orden lógico:
 - 00 setup e inventario
 - 01 preprocesamiento y epochs limpias
 - 02 extracción de features y matriz final
 - 03 baselines y split holdout

- 04 comparación de modelos sin tuning
- 05 tuning con Optuna y modelo final
- 06 evaluación final, holdout, LOSO y tabla maestra
- 07 SHAP
- 08 ablations
- reports/ (tablas CSV/JSON con resultados)
- figures/ (figuras usadas en el análisis)
- models/ (best_model.pkl y best_hyperparameters.json)
- requirements.txt: requerimientos necesarios

9. Cierre y relación con el paper del dataset

El dataset fue creado para evaluar si un headset de EEG de consumo (Muse 2) puede capturar el componente N400 durante una tarea de relación semántica, y además si se puede trabajar con el fenómeno en análisis de single-trial. En el artículo del dataset se describe un flujo de preprocesamiento estándar para ERPs (filtrado, re-referenciación, extracción de epochs -100 a 900 ms respecto al target, baseline -100 a 0 ms, rechazo por amplitud y uso de ensayos correctos), y se reporta que la señal tiene suficiente calidad para estudiar diferencias relacionadas con procesamiento semántico, aunque con limitaciones típicas de baja densidad de electrodos.

Nuestro aporte en Etapa 2 es que, usando features tabulares y una evaluación estricta por sujeto (GroupKFold y holdout por sujeto), se observa que existe señal discriminativa a nivel single-trial, pero el desempeño es moderado. El modelo final (LightGBM tuneado) mejora sobre baselines y se mantiene estable al evaluar sujetos no vistos (macro F1 ~0.58 en holdout), pero también se ve claramente que la variación por sujeto es alta (LOSO std ~0.09) y que la ventana N400 por sí sola no alcanza el rendimiento del pipeline completo. En otras palabras, el dataset sí permite hacer single-trial analysis, pero el efecto es sutil y el modelo termina usando sobre todo medidas de variabilidad temporal y ratios espectrales, más que depender únicamente de la amplitud media N400.

Fuentes

- Hayes, H. B., & Magne, C. L. (2025). Dataset of 37-subject EEG recordings using a low-cost mobile EEG headset during a semantic relatedness judgment task. *Data in Brief*, 59, 111390. <https://doi.org/10.1016/j.dib.2025.111390>
- OSF: Muse Validation for Language ERPs. <https://osf.io/u6y9g/>